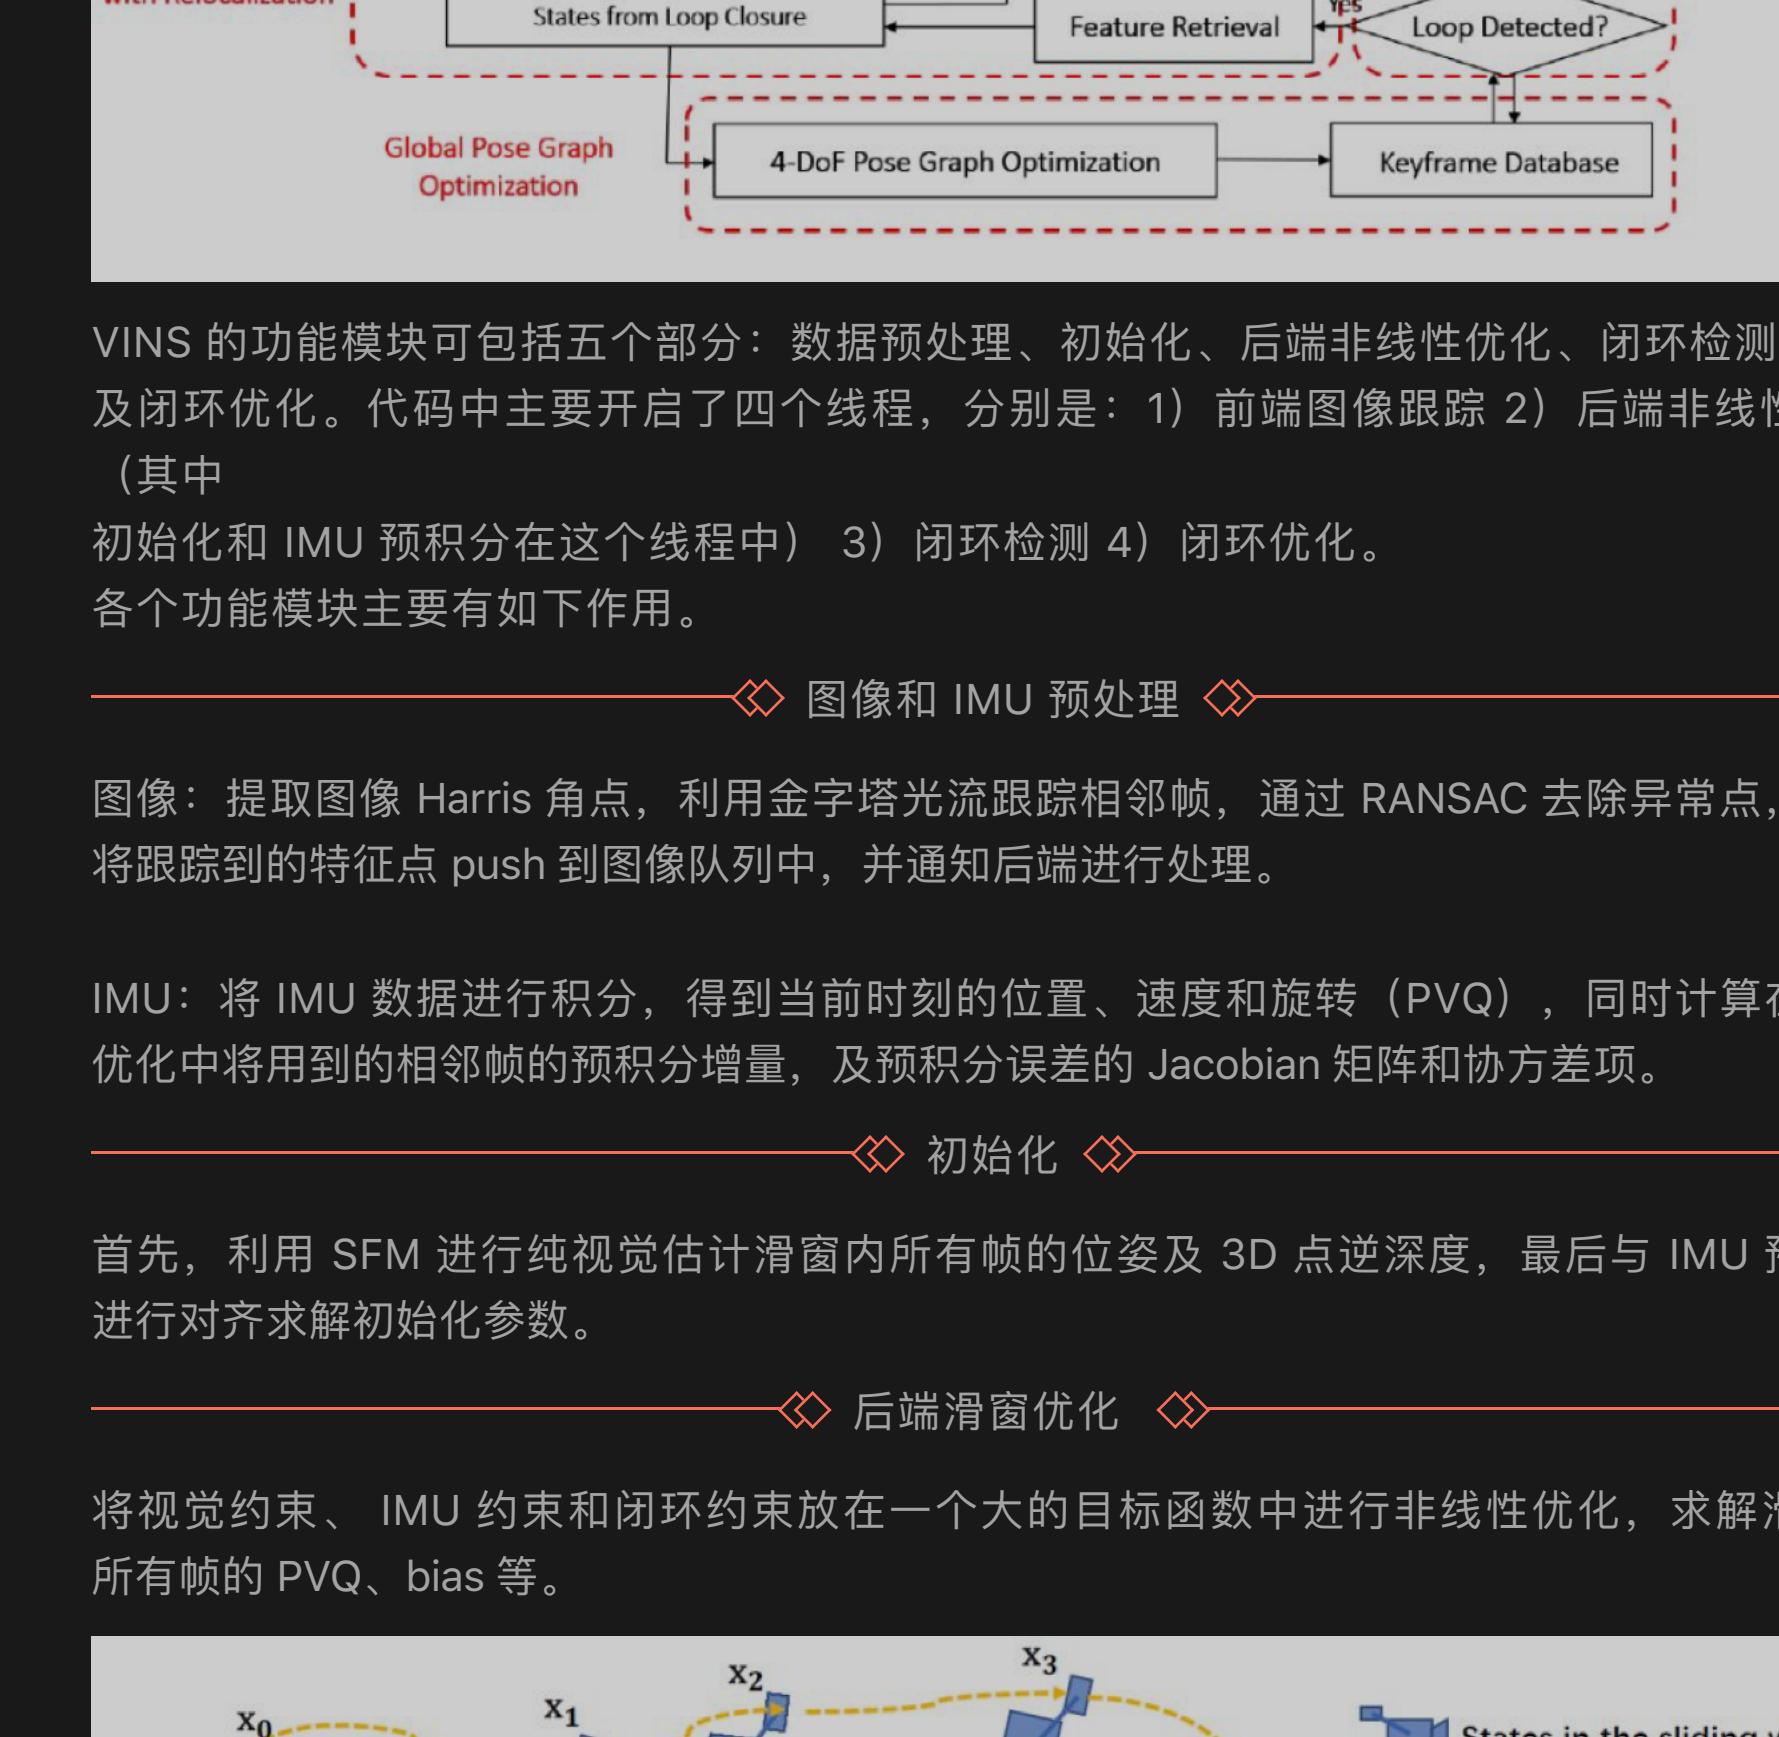


微信扫一扫
关注该公众号



VINS 的功能模块可包括五个部分：数据预处理、初始化、后端非线性优化、闭环检测及闭环优化。代码中主要开启了四个线程，分别是：1) 前端图像跟踪 2) 后端非线性优化（其中初始化和 IMU 预积分在这个线程中）3) 闭环检测 4) 闭环优化。

各个功能模块主要有如下作用。

◆◆◆ 图像和 IMU 预处理 ◆◆◆

图像：提取图像 Harris 角点，利用金字塔光流跟踪相位帧，通过 RANSAC 去除异常点，最后将跟踪到的特征点 push 到图像队列中，并通知后端进行处理。

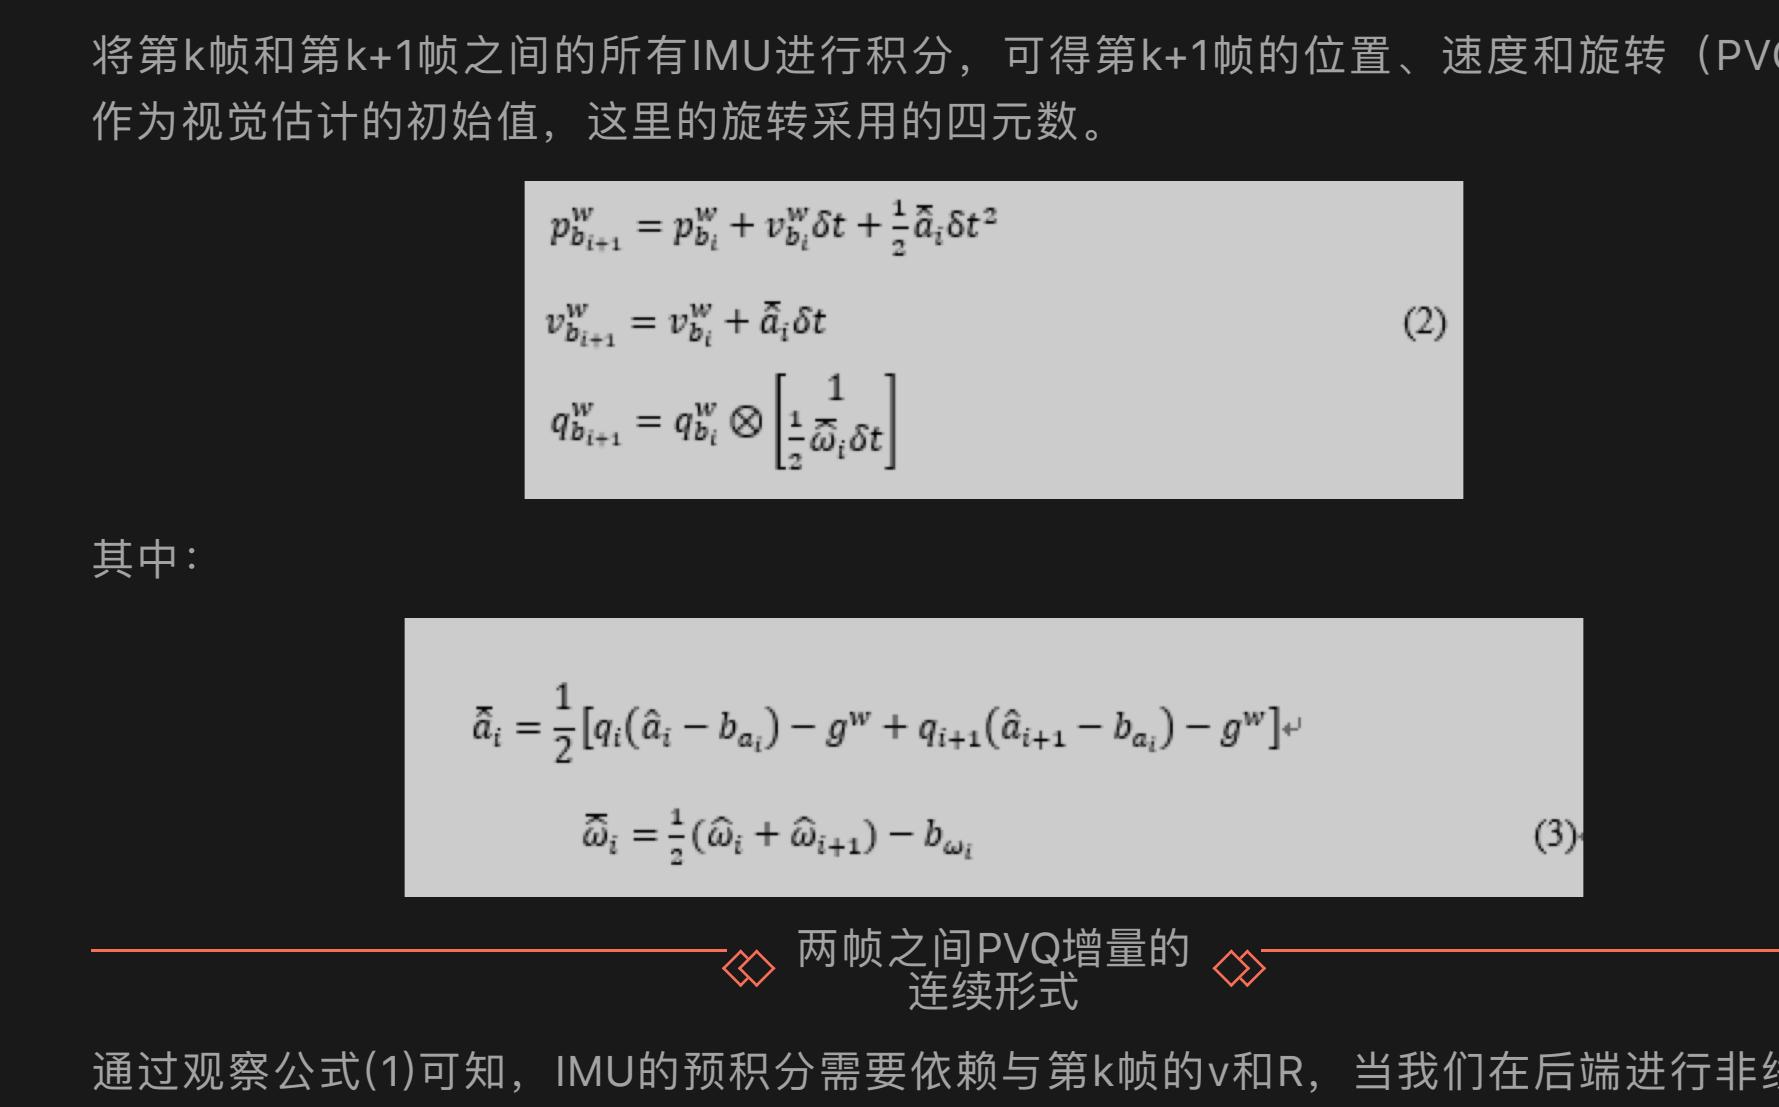
IMU：将 IMU 数据进行积分，得到当前时刻的位置、速度和旋转 (PVQ)，同时计算在后端优化中将用到的相邻帧的预积分增量，及预积分误差的 Jacobian 矩阵和协方差矩阵。

◆◆◆ 初始化 ◆◆◆

首先，利用 SfM 进行纯视觉估计滑窗内所有帧的位姿及 3D 点逆深度，最后与 IMU 预积分进行对齐求解初始化参数。

◆◆◆ 后端滑窗优化 ◆◆◆

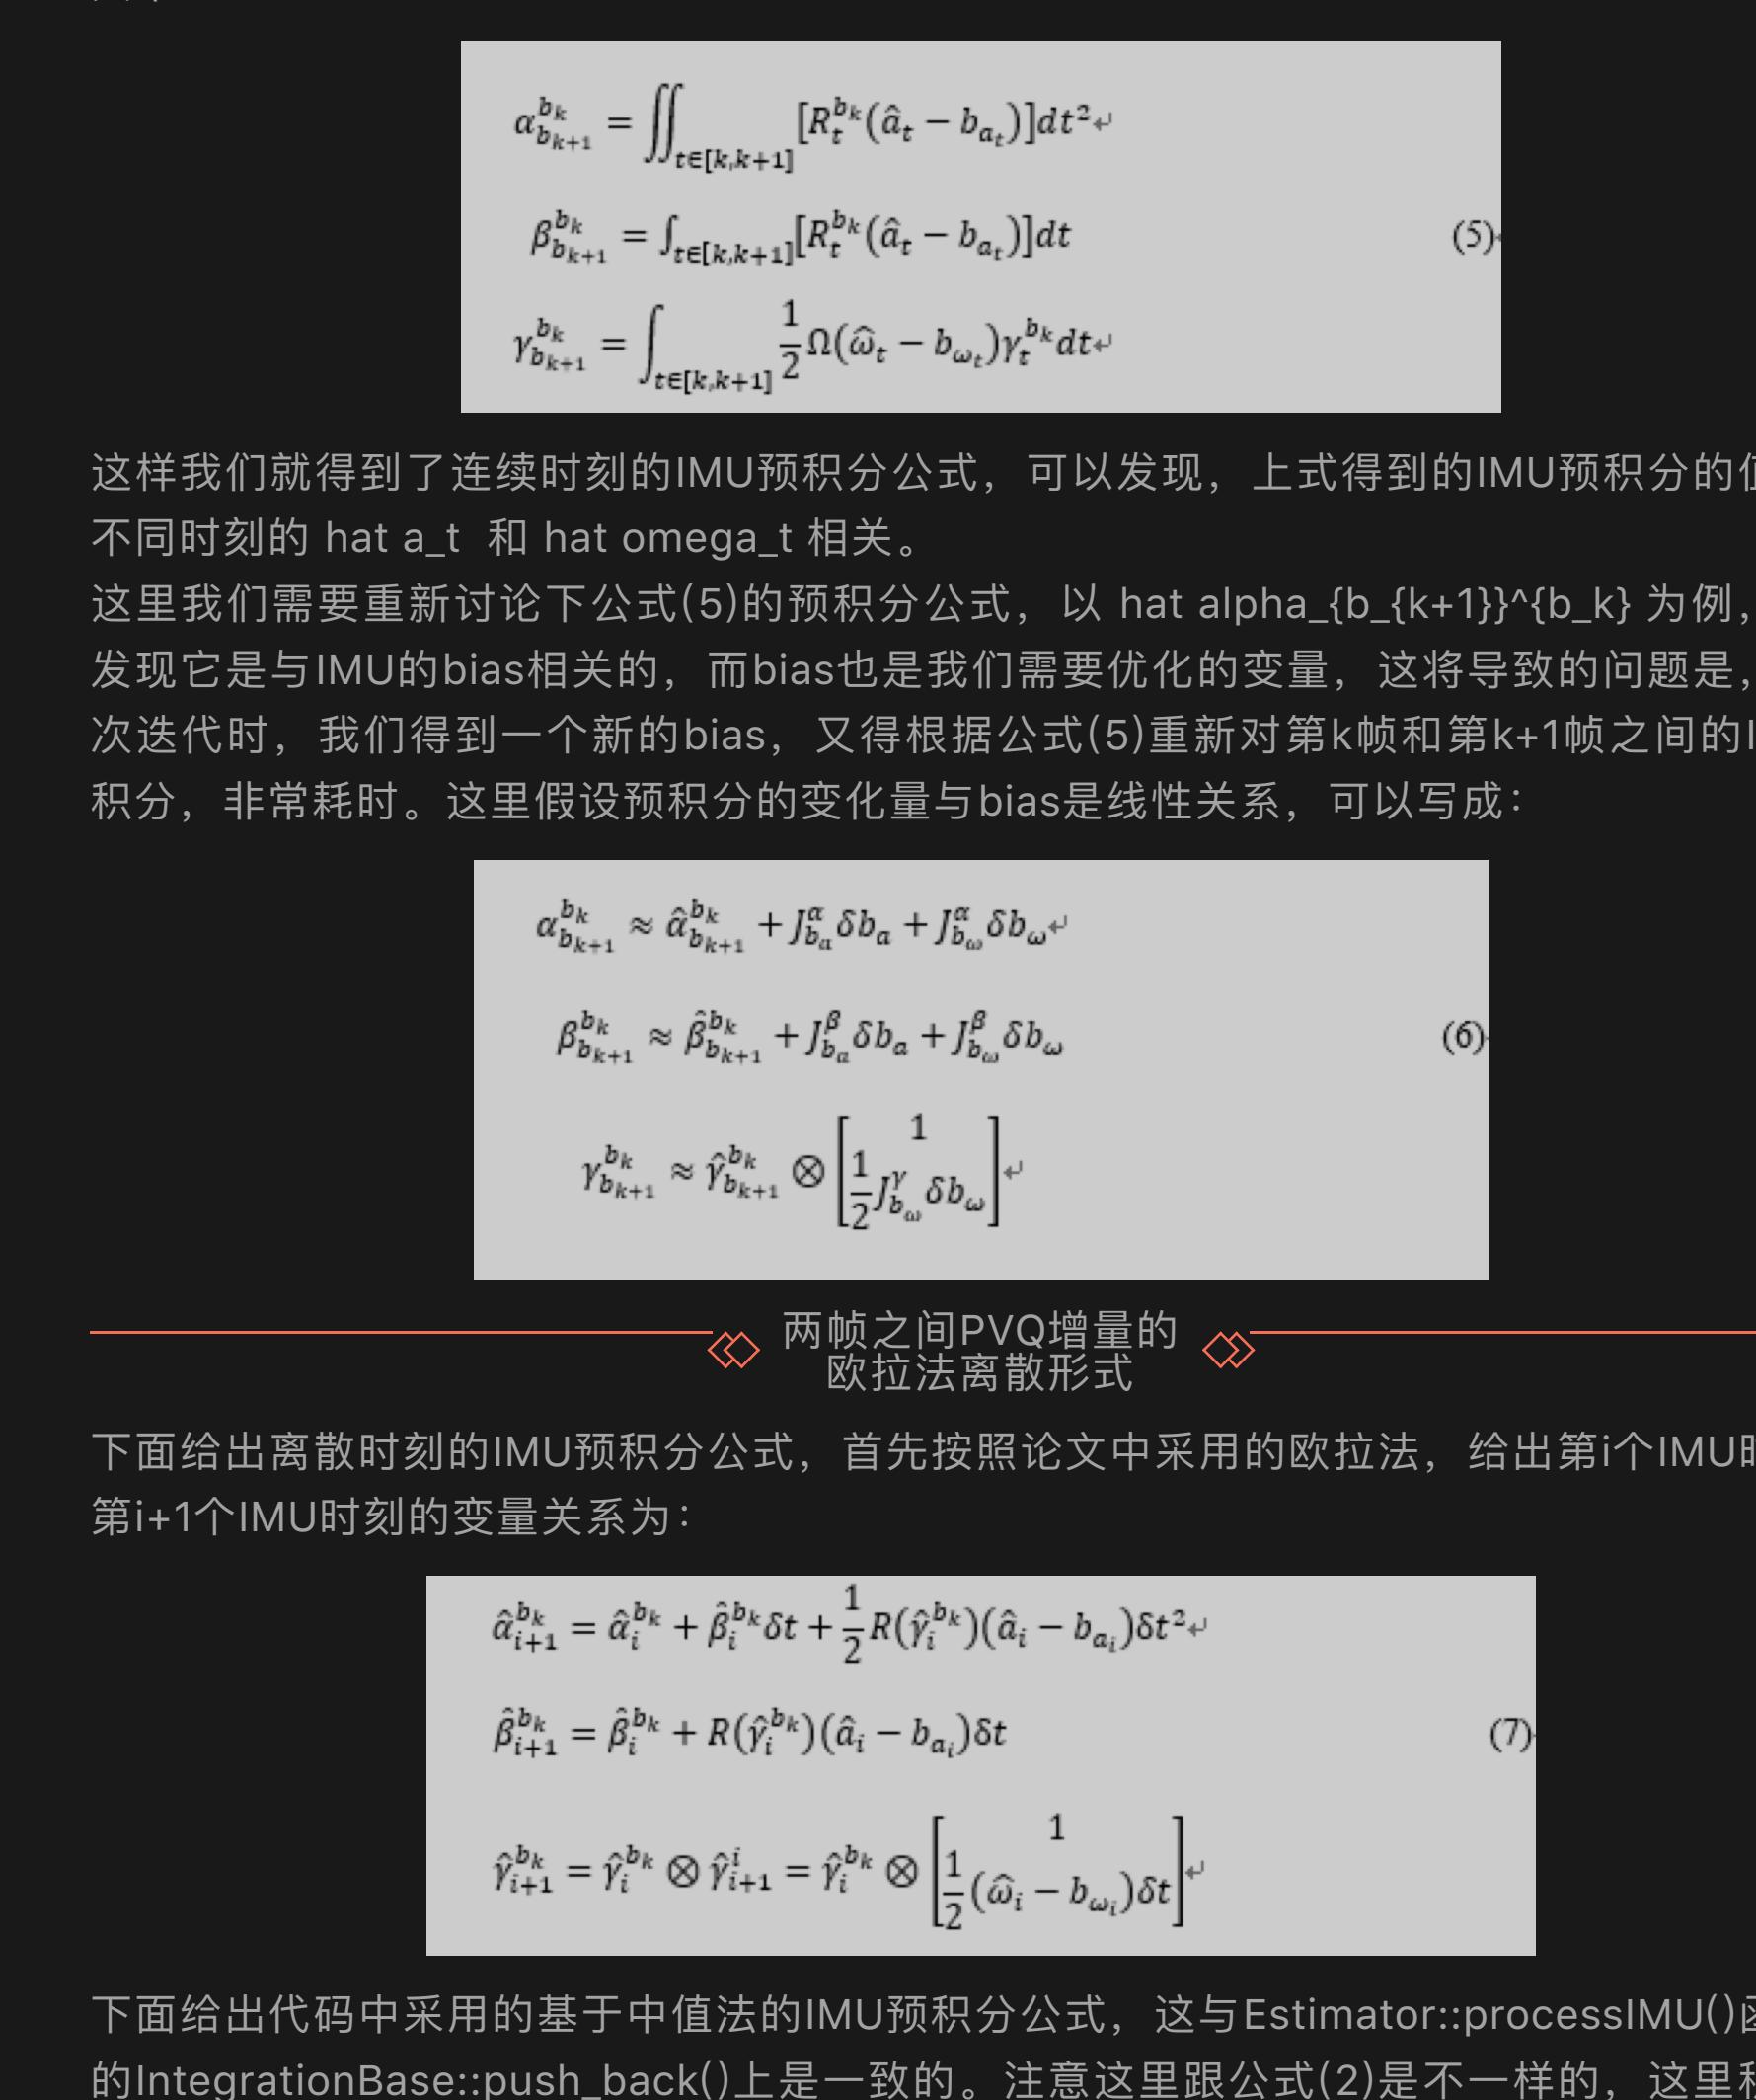
将视觉约束、IMU 约束和闭环约束放在一个大的目标函数中进行非线性优化，求解滑窗内所有帧的 PVQ、bias 等。



◆◆◆ 闭环检测和优化 ◆◆◆

利用 DBOW 进行闭环检测，当检测成功后进行重定位，最后对整个相机轨迹进行闭环优化。

◆◆◆ IMU 预积分 ◆◆◆



◆◆◆ 当前时刻 PVQ 的连续形式 ◆◆◆

将第 k 帧和第 k+1 帧之间的所有 IMU 进行积分，可得第 k+1 帧的位置、速度和旋转 (PVQ)，作为视觉估计的初值，这里的旋转采用的四元数。

◆◆◆ 当前时刻 PVQ 的连续形式 ◆◆◆

将第 k 帧和第 k+1 帧之间的所有 IMU 进行积分，可得第 k+1 帧的位置、速度和旋转 (PVQ)，作为视觉估计的初值，这里的旋转采用的四元数。

$$\begin{aligned} p_{b_{k+1}}^w &= p_{b_k}^w + v_{b_k}^w \Delta t_k + \int_{t \in [k, k+1]} [R_t^w (\hat{a}_t - b_{a_t}) - g^w] dt^2 \\ v_{b_{k+1}}^w &= v_{b_k}^w + \int_{t \in [k, k+1]} [R_t^w (\hat{a}_t - b_{a_t}) - g^w] dt \\ q_{b_{k+1}}^w &= q_{b_k}^w \otimes \int_{t \in [k, k+1]} \frac{1}{2} \Omega (\hat{a}_t - b_{\omega_t}) q_{b_k}^w dt \end{aligned} \quad (1)$$

其中， \hat{a}_{a_t} 和 Ω 分别为 IMU 测量的加速度和角速度，是在 Body 自身坐标系，世界坐标系是 IMU 所在的领导坐标系，上式的旋转公式推导后期会提供参考附录。

◆◆◆ 当前时刻 PVQ 的连续形式 ◆◆◆

将第 k 帧和第 k+1 帧之间的所有 IMU 进行积分，可得第 k+1 帧的位置、速度和旋转 (PVQ)，作为视觉估计的初值，这里的旋转采用的四元数。

$$\begin{aligned} p_{b_{k+1}}^w &= p_{b_k}^w + v_{b_k}^w \Delta t_k + \frac{1}{2} \tilde{\theta} \Delta t^2 \\ v_{b_{k+1}}^w &= v_{b_k}^w + \tilde{\theta} \Delta t \\ q_{b_{k+1}}^w &= q_{b_k}^w \otimes \left[\frac{1}{2} \tilde{\theta} \Delta t \right] \end{aligned} \quad (2)$$

其中：

$$\begin{aligned} \tilde{\theta} &= \frac{1}{2} [\hat{q}_k (\hat{a}_k - b_{a_k}) - g^w + \hat{q}_{k+1} (\hat{a}_{k+1} - b_{a_k}) - g^w] \\ \tilde{\omega} &= \frac{1}{2} (\hat{\omega}_k + \hat{\omega}_{k+1}) - b_{\omega_k} \end{aligned} \quad (3)$$

◆◆◆ 两帧之间 PVQ 增量的 ◆◆◆

通过观察公式(1)可知，IMU 的预积分分要依赖与第 k 帧的初值 R_k 。当我们在后端进行非线性优化时，需要迭代更新第 k 帧的初值和 R_k 。这将导致我们需要根据每次迭代后值重新进行积分，这将非常耗时。因此，我们考虑将优化变量从第 k 帧到第 k+1 帧的 IMU 预积分分中分离出来，通过对公式 (1) 左右两侧各乘 $\partial_{b_k}^w$ ，可化简为：

$$\begin{aligned} p_{b_k}^w p_{b_{k+1}}^w &= R_{b_k}^w (p_{b_k}^w + v_{b_k}^w \Delta t_k - \frac{1}{2} g^w \Delta t_k^2) + a_{b_{k+1}}^{b_k} \\ R_{b_k}^w p_{b_{k+1}}^w &= R_{b_k}^w (v_{b_k}^w - g^w \Delta t_k) + \beta_{b_{k+1}}^{b_k} \\ q_{b_k}^w \otimes q_{b_{k+1}}^w &= v_{b_k}^w \end{aligned} \quad (4)$$

其中：

$$\begin{aligned} a_{b_{k+1}}^{b_k} &= \int_{t \in [k, k+1]} [R_t^w (\hat{a}_t - b_{a_t}) - g^w] dt^2 \\ \beta_{b_{k+1}}^{b_k} &= \int_{t \in [k, k+1]} [R_t^w (\hat{a}_t - b_{a_t})] dt \\ v_{b_{k+1}}^w &= \int_{t \in [k, k+1]} \frac{1}{2} \Omega (\hat{a}_t - b_{\omega_t}) dt \end{aligned} \quad (5)$$

这样我们就得到了连续时刻的 IMU 预积分分公式，可以发现，上式得到的 IMU 预积分分的值只与不同时刻的 \hat{a}_{a_t} 和 Ω 相关。

这里我们需要重新讨论下公式(5)的预积分公式，以 $\text{hat alpha}_{(b_k+1)}^w \times \text{b}_k$ 为例，我们发现它是与 IMU 的 bias 相关的，而 bias 是我们需优化的变量，这将导致的问题是，当每次迭代时，我们得到一个新的 bias，又得根据公式(5)重新对第 k 帧和第 k+1 帧之间的 IMU 预积分分，非常耗时。这里假设预积分的变化量与 bias 是线性关系，可以写成：

$$\begin{aligned} a_{b_{k+1}}^{b_k} &\approx a_{b_{k+1}}^{b_k} + J_{b_{k+1}}^b \delta b_k + J_{b_{k+1}}^b \delta b_{\omega} \\ p_{b_{k+1}}^w &\approx p_{b_k}^w + J_{b_{k+1}}^b \delta b_k + J_{b_{k+1}}^b \delta b_{\omega} \\ v_{b_{k+1}}^w &\approx v_{b_k}^w \otimes \left[\frac{1}{2} \int_{t \in [k, k+1]} \delta b_{\omega_t} dt \right] \end{aligned} \quad (6)$$

◆◆◆ 两帧之间 PVQ 增量的 ◆◆◆

欧拉法离散形式：

下面给出代码中采用的基于中值法的 IMU 预积分分公式，这与 Estimator::processIMU() 函数中的 IntegrationBase::push_back() 上是一致的。注意这里跟公式(2)是不一样的，这里积分出来的是前后两帧之间的 IMU 增量信息，而公式(2)给出的当前帧时刻的物理量信息。

$$\begin{aligned} \hat{a}_{t+1}^{b_k} &= \hat{a}_t^{b_k} + \hat{p}_{t+1}^{b_k} \delta t + \frac{1}{2} R(\hat{y}_t^{b_k}) (\hat{a}_t - b_{a_t}) \delta t^2 \\ \hat{p}_{t+1}^{b_k} &= \hat{p}_t^{b_k} + R(\hat{y}_t^{b_k}) \hat{a}_t \delta t \\ \hat{y}_{t+1}^{b_k} &= \hat{y}_t^{b_k} \otimes \hat{q}_{t+1}^w \otimes \left[\frac{1}{2} \int_{t \in [k, k+1]} \delta b_{\omega_t} dt \right] \end{aligned} \quad (7)$$

下面给出代码中采用的基于中值法的 IMU 预积分分公式，这与 Estimator::processIMU() 函数中的 IntegrationBase::push_back() 上是一致的。注意这里跟公式(2)是不一样的，这里积分出来的是前后两帧之间的 IMU 增量信息，而公式(2)给出的当前帧时刻的物理量信息。

$$\hat{a}_{t+1}^{b_k} = \hat{a}_t^{b_k} + \hat{p}_{t+1}^{b_k} \delta t + \frac{1}{2} R(\hat{y}_t^{b_k}) (\hat{a}_t - b_{a_t}) \delta t^2 \quad (8)$$

其中：

$$\hat{a}_t^{b_k} = \frac{1}{2} [\hat{q}_k (\hat{a}_k - b_{a_k}) + \hat{q}_{k+1} (\hat{a}_{k+1} - b_{a_k})] \quad (9)$$

◆◆◆ 连续形式下 PVQ 增量的 ◆◆◆

误差、协方差及 Jacobian

IMU 在每一个时刻积分出来的值是有误差的，下面我们将误差进行分析。首先我们直接给出在 t 时刻积分出来的误差值：

$$F_t = I + F_t \delta t, \quad V = G_t \delta t \quad (10)$$

根据导数定义可知：

$$\begin{aligned} \delta z_t^{b_k} &= \lim_{\delta t \rightarrow 0} \frac{\delta z_{t+\delta t}^{b_k} - \delta z_t^{b_k}}{\delta t} \\ \delta z_{t+\delta t}^{b_k} &= \delta z_t^{b_k} + \delta z_t^{b_k} \delta t + \delta z_t^{b_k} \delta b_k + V \delta t + G_t \delta t \end{aligned} \quad (11)$$

为了简化下一节中对离散形式的分析，上式中我们令

$$F = I + F_t \delta t, \quad V = G_t \delta t \quad (12)$$

这里我们对公式(11)的 IMU 误差运动方程再说明，将上式和 EKF 对比可知，上式恰好给出了如 EKF 一般对非线性系统线性化的过程，这里的意义是表示下一个时刻的 IMU 测量误差与上一个时刻的线性关系。这样我们根据当前时刻的值，可以预测出下一个时刻的均值和协方差，而公式(11)给出的是均值预测，协方差预测公式如下：

$$P_{t+\delta t}^{b_k} = (I + F_t \delta t) P_t^{b_k} (I + F_t \delta t)^T + (G_t \delta t) Q (G_t \delta t)^T \quad (13)$$

上面给出了协方差的迭代公式，初始值 $P_{(b_k)}^{b_k} = \{b_k\}$ 。其中，Q 为表示噪声项的对角协方差矩阵：

$$Q^{12 \times 12} = \begin{bmatrix} \sigma_a^2 & 0 & 0 & 0 & 0 & 0 \\ 0 & \sigma_a^2 & 0 & 0 & 0 & 0 \\ 0 & 0 & \sigma_a^2 & 0 & 0 & 0 \\ 0 & 0 & 0 & \sigma_a^2 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sigma_a^2 & 0 \\ 0 & 0 & 0 & 0 & 0 & \sigma_a^2 \end{bmatrix} \quad (14)$$

◆◆◆ 离散形式下 PVQ 增量的 ◆◆◆

误差分析：

我们首先直接给出 PVQ 增量误差在矩阵形式下的矩阵形式，为了与代码一致，我们修改一下量顺序。这和代码中 midPointIntegration() 函数是一致的。（但不知为何计算的 V 中与前四

个噪声项相关的那个负号。）

$$\begin{bmatrix} \delta a_t^{b_k} \\ \delta p_t^{b_k} \\ \delta \theta_t^{b_k} \\ \delta b_{a_t} \\ \delta b_{\omega_t} \end{bmatrix} = \begin{bmatrix} 0 & 0 & I & 0 & 0 \\ 0 & 0 & -R_{t+1}^w (\hat{a}_t - b_{a_t})^T & 0 & -R_{t+1}^w \\ 0 & 0 & 0 & 0 & I \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \delta a_t^{b_k} \\ \delta p_t^{b_k} \\ \delta \theta_t^{b_k} \\ \delta b_{a_t} \\ \delta b_{\omega_t} \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ -R_{t+1}^w & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & n_w \end{bmatrix} \quad (15)$$

其中，推导可参考附录。

$$J_{t+\delta t} = (I + F_t \delta t) J_t \quad (16)$$

上式推导可参考附录。下面我们讨论它的作用，将其可以简写为：

$$\delta z_t^{b_k} = F_t \delta z_t^{b_k} + G_t n_t \quad (17)$$

根据导数定义可知：

$$\begin{aligned} \delta z_t^{b_k} &= \lim_{\delta t \rightarrow 0} \frac{\delta z_{t+\delta t}^{b_k} - \delta z_t^{b_k}}{\delta t} \\ \delta z_{t+\delta t}^{b_k} &= \delta z_t^{b_k} + \delta z_t^{b_k} \delta t + \delta z_t^{b_k} \delta b_k + V \delta t + G_t \delta t \end{aligned} \quad (18)$$

其中，初始值 $P_{(b_k)} = 0$ 。Q 为表示噪声项的对角协方差矩阵：

$$Q^{18 \times 18} = \begin{bmatrix} \sigma_a^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & \sigma_a^2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \sigma_a^2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \sigma_a^2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sigma_{b_a}^2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \sigma_{b_a}^2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & \sigma_{b_a}^2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma_{b_w}^2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & \sigma_{b_w}^2 \end{bmatrix} \quad (19)$$

未完待续~

欢迎来到泡泡论坛。这里有大牛为你解答关于 SLAM 的任何疑惑，

有任何问题，或者想刷帖回答问题，泡泡论坛欢迎你！

泡泡网站：www.paopaorobot.org

泡泡论坛：<http://paopaorobot.org/bbs/>

泡泡机器人 SLAM 的原创内容均由泡泡机器人的成员花费大量心血制作而成，希望大家珍惜我们的劳动成果，转载请注明出处（泡泡机器人 SLAM）微信公众号，否则侵权必究！同时，我们也欢迎各位转载到自己的朋友圈，让更多的人能进入到 SLAM 这个领域中，让我们共同为推进中国的 SLAM 事业而努力！

商业合作及转载请联系 hufuqiang_robot@hotmail.com