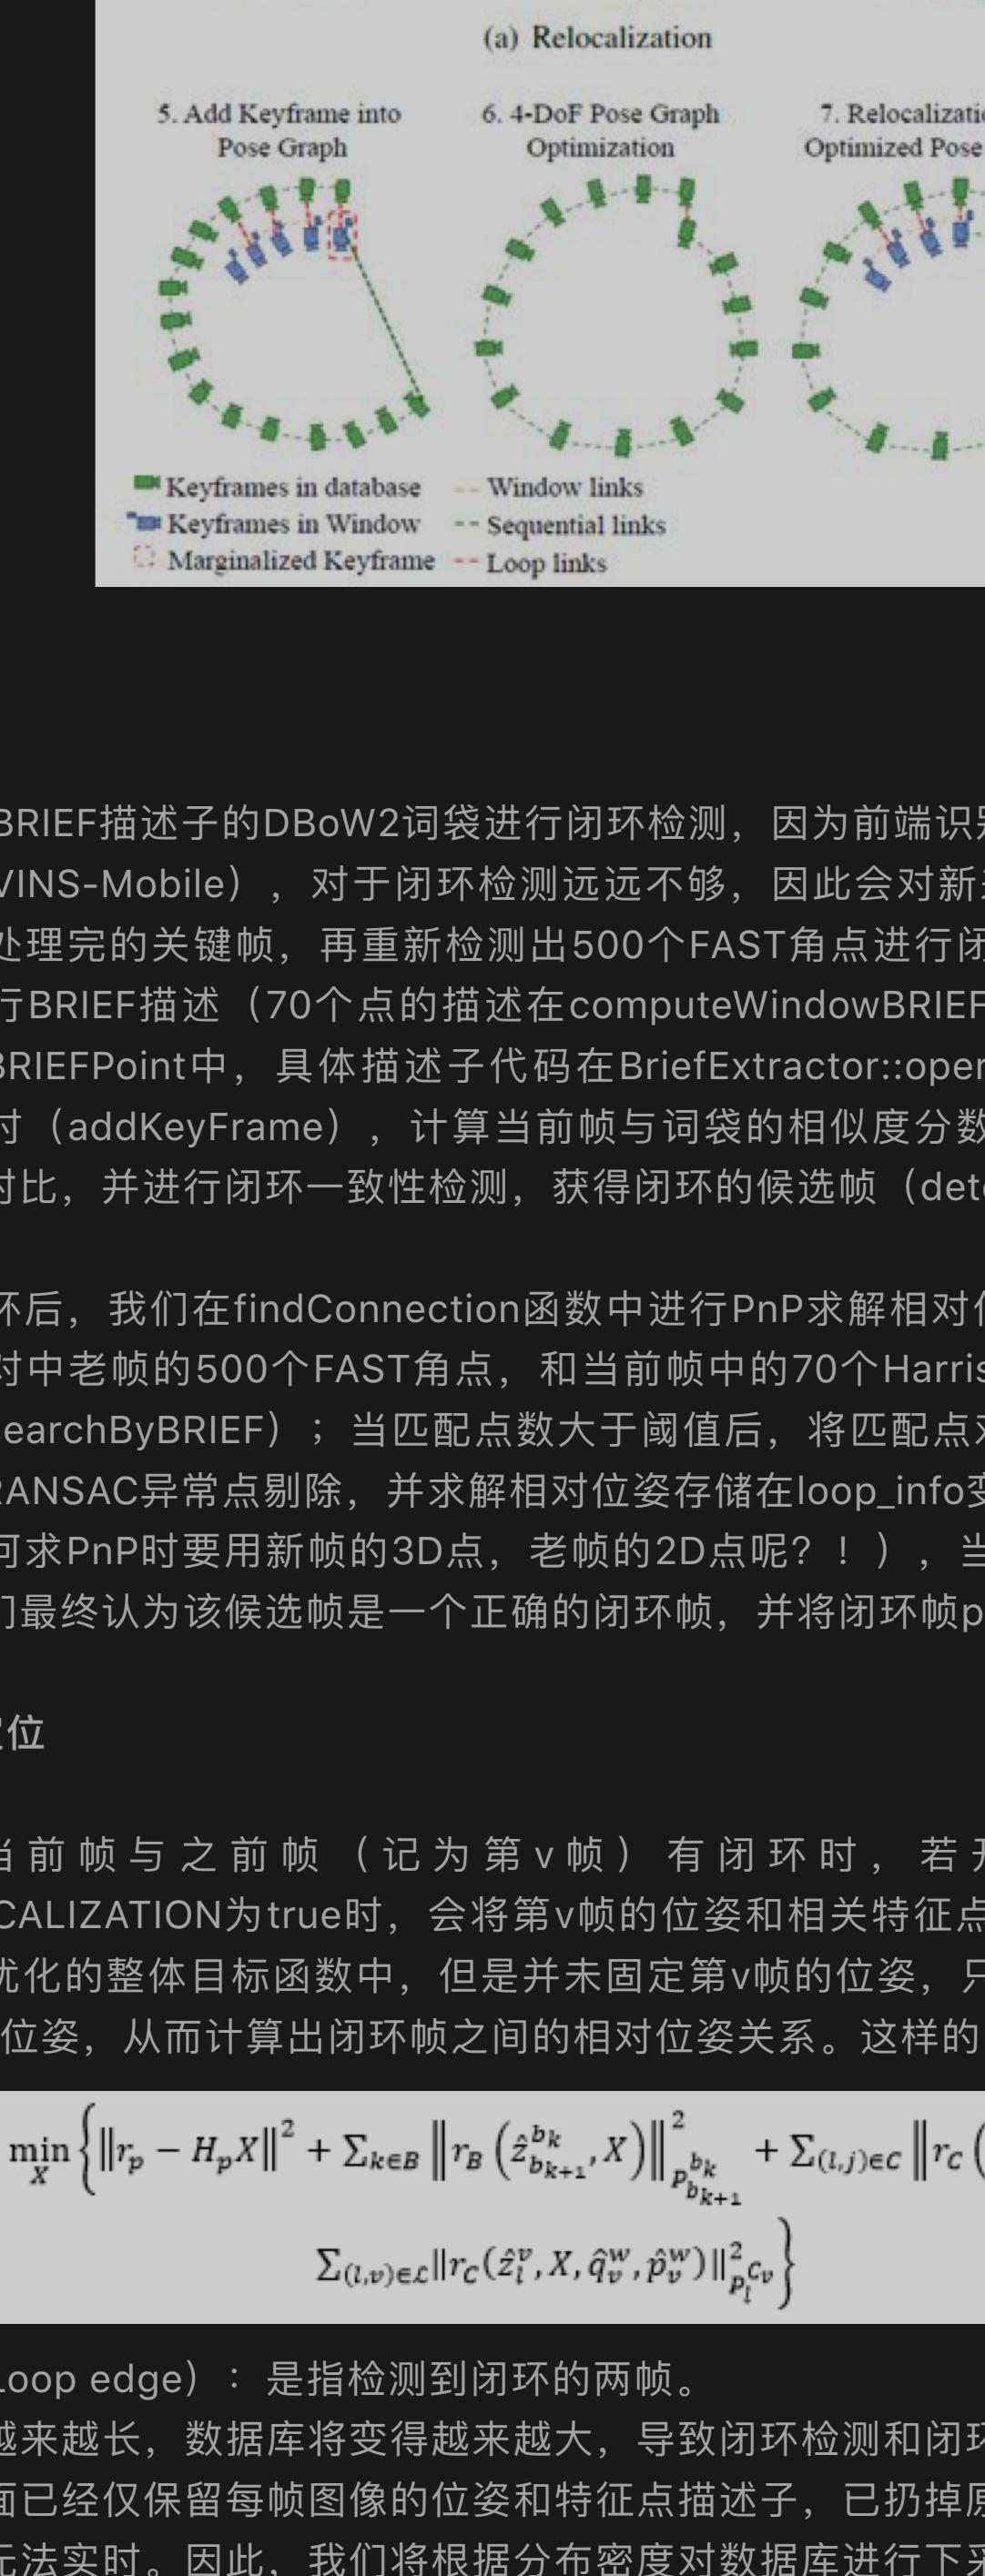


7.闭环检测和优化



7.1 闭环检测

VINS是使用BRIEF词袋进行闭环检测，因为前端识别的Harris角点数量通常只有70个（VINS-Mobile），对于闭环检测远远不够，因此会对新的KeyFrame即后端非线性优化刚处理完的关键帧，再重新检测出500个FAST角点进行闭环检测，同时对所有新老点进行BRIEF描述（70个点的描述在computeWindowBRIEFPoint中，新的500个点在computeBRIEFPoint中，具体描述子代码在briefExtractor::operator+），然后，将KF添加到数据中时（addKeyFrame），计算当前帧与词袋的相似度分数，并与关键帧数据库中所有帧进行对比，并进行闭环一致性检测，获得闭环的候选帧（detectLoop）。

当检测到闭环后，我们在findConnection函数中进行PnP求解相对位姿，首先利用BRIEF描述子对闭环中老帧的500个FAST角点，和当前帧中的70个Harris角点进行基于描述子的邻域匹配（searchByBRIEF）；当匹配点数大于阈值后，将匹配点对利用PnP+RANSAC求基础矩阵进行RANSAC异常点剔除，并求解相对位姿；在loop_info变量中用于后续的闭环优化使用（为何用PnP时要用新的3D点，老帧的2D点呢？），当剔除后的匹配点数超过阈值时，我们认为该候选帧是一个正确的闭环帧，并将闭环帧push到optimize_buf中。

7.2 快速重定位

当检测到当前帧与之前帧（记为第v帧）有闭环时，若开启快速重定位，即FAST_RELOCALIZATION为true时，会将第v帧的位姿和相关特征点作为视觉约束项，加到后端非线性优化的整体目标函数中，但是并未固定第v帧的位姿，只是用滑窗优化来更精确计算第v帧的位姿，从而计算出闭环帧之间的相对位姿关系。这样的目标函数可写为：

$$\min_X \left\{ \|r_p - H_p X\|^2 + \sum_{k \in S} \|r_k(z_{b_k}^k, X)\|_{P_{b_k}}^2 + \sum_{(i,j) \in C} \|r_c(z_i^j, X)\|_{P_{c_i}}^2 + \sum_{(l,w) \in L} \|r_w(z_l^w, X, t_w^w, \hat{p}_w^w)\|_{V_{c_w}}^2 \right\} \quad (44)$$

b. 闭环边（Loop edge）：是指检测到闭环的两条边。

当运行时间越来越长，数据库将变得越来越大，导致闭环检测和闭环优化的耗时也将越来越长。虽然前面已经保留每帧图像的位姿和特征点描述子，已扔掉原始图像，但是当运行几小时后仍将无法实时。因此，我们将根据分布密度对数据库进行下采样，保留那些与周围帧的位置和角度不同的，而丢弃集中在一起的帧（代码对KeyFrameDatabase::downsample）。

7.4 闭环优化

当从滑窗内滑出的帧与数据库中的帧为闭环帧时，则对数据库的所有帧进行闭环优化。因为前面已经跟重力对齐，所以根据重力方向可以观测出俯仰θ和翻滚ω角度，即pitch和roll可观。因此闭环优化时，我们仅优化位置x,y,z和偏航角yaw这四个自由度。

那么，第i帧和第j帧的残差可写成：

$$r_{ij}(p_i^w, \psi_i, p_j^w, \psi_j) = \begin{bmatrix} R(\phi_i, \theta_i, \psi_i)^{-1}(p_i^w - p_j^w) - \hat{p}_{ij} \\ \psi_j - \psi_i - \hat{\psi}_{ij} \end{bmatrix} \quad (47)$$

所有序列边和回环边的整体目标函数可写为：

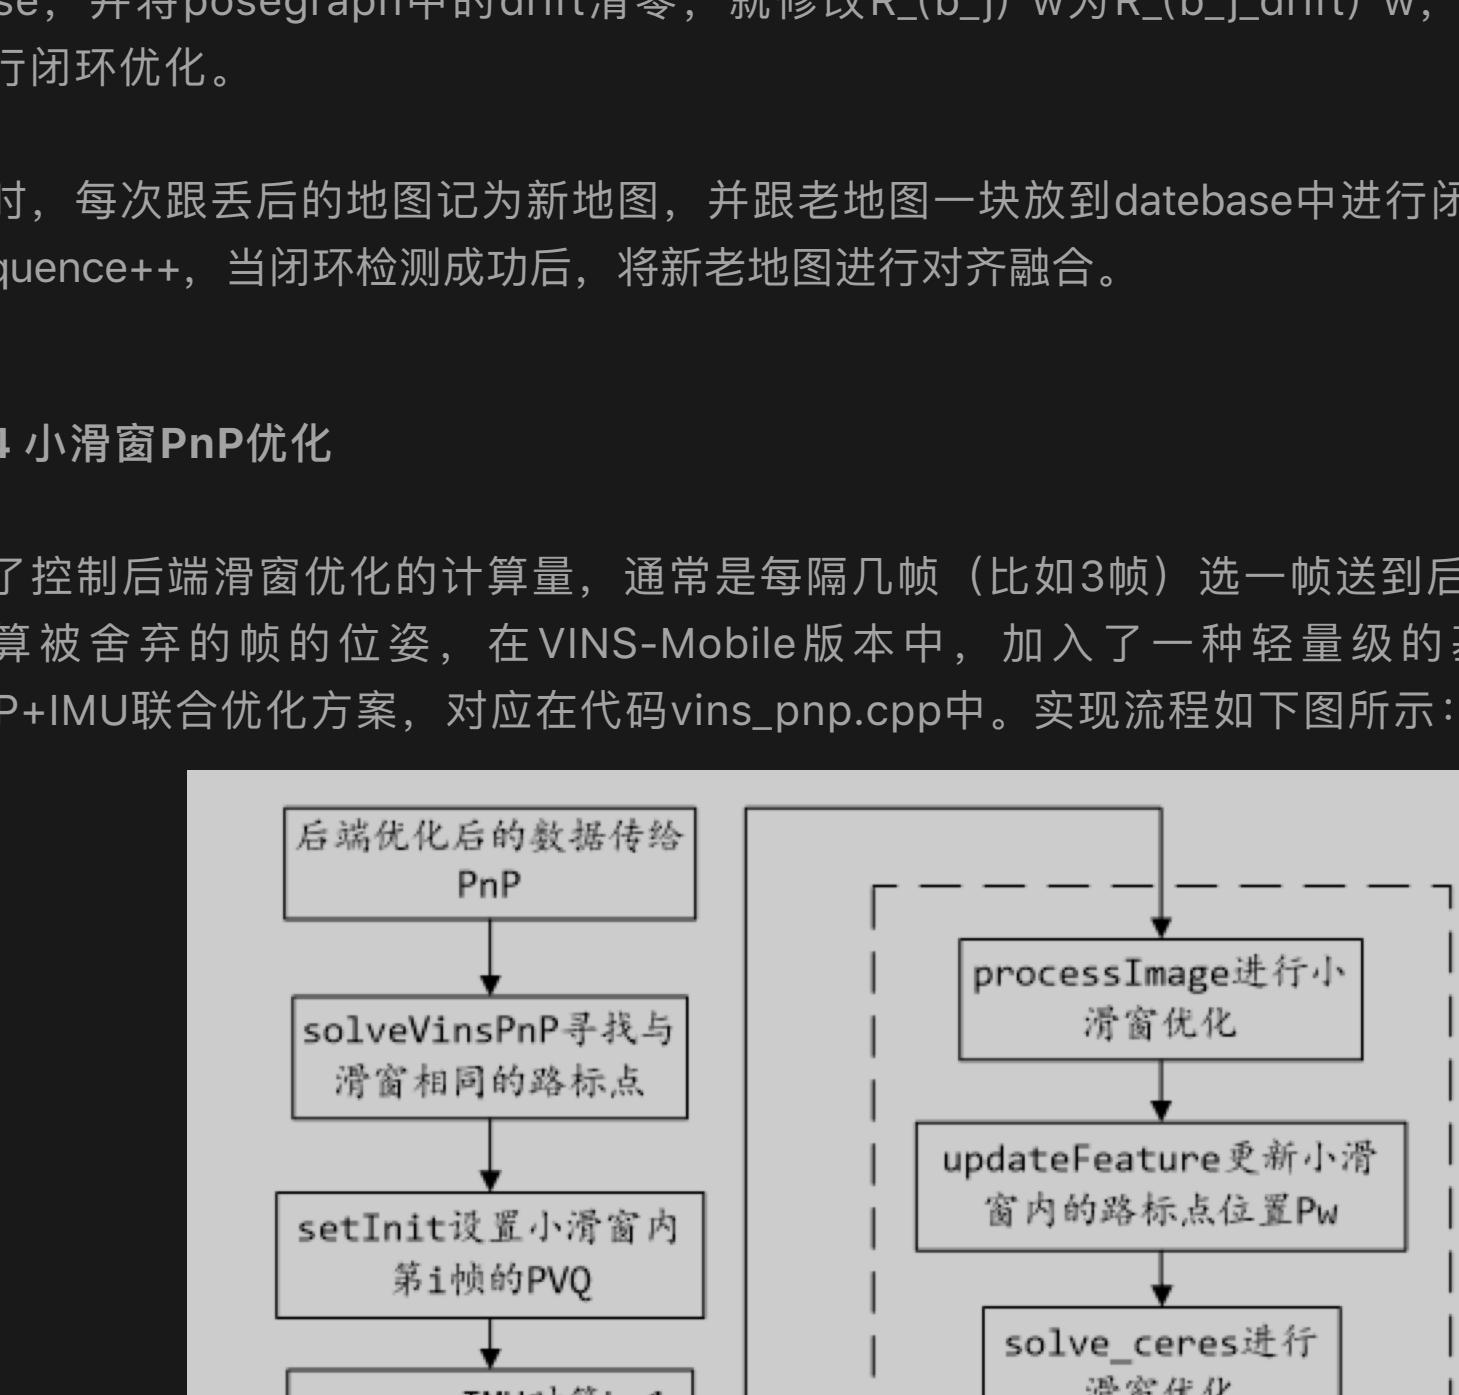
$$\min_{p,w} \left\{ \sum_{(i,j) \in S} \|r_{ij}\|^2 + \sum_{(i,j) \in L} h(\|r_{ij}\|^2) \right\} \quad (48)$$

其中，S为序列边，L为回环边，h()为huber核函数。对应代码为KeyFrameDatabase::optimize4DoFLoopPoseGraph，注意代码中采用的Ceres自动求导方式。

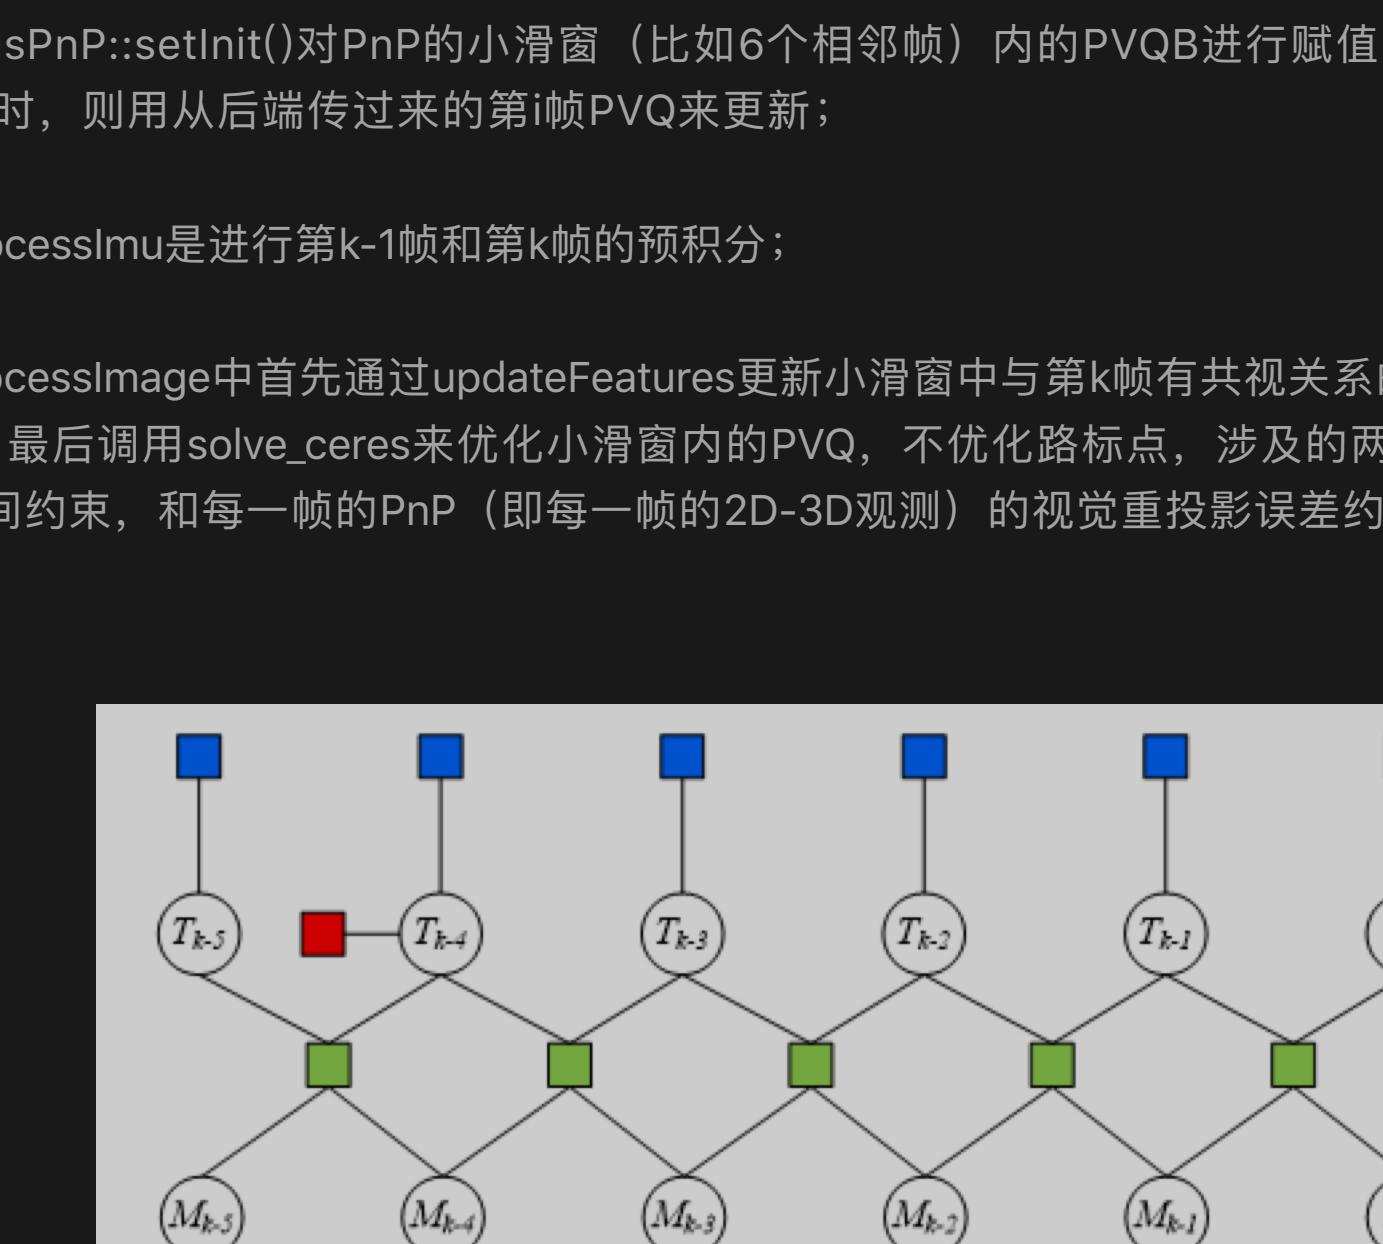
到目前为止，我们就完成了对整个轨迹的闭环优化。

7.5 程序逻辑

下面我们对闭环与后端优化的关系再进行详细说明。



假设发生闭环的两端为滑窗内的第i帧（蓝色帧），和数据库中的第j帧（红色帧）。令第i帧的位姿为T_(w_i←b_i)，第j帧的位姿为T_(w_2←b_j)，值得注意的是，两帧的世界系并不相同。滑窗所在的世界系w2为原世界系w1产生累积误差后的结果，重定位需要做的是将w2改到w1。那么，根据PnP可得到两帧之间的相对位姿T_(w_2←b_j)，注意这里的PnP是用的第1帧的2D点和第2帧的3D点。但是PnP计算的相对位姿通常不准确，因此，可将PnP的结果作为初始值传到滑窗中，优化得到第1帧在世界系w2中的位姿T_(w_1←b_j)。为了将w2改到w1，我们计算累积偏移位姿：T_(w_1←w_2) = T_(w_1←b_j) * T_(w_2←b_j)^{-1}。这样的话，就可以将当前的第j帧重定位到原世界系中：T_(w_1←w_2) = T_(w_1←w_2) * T_(w_2←b_j)。如图所示：



上图中，蓝线为正常的闭环优化流程，即通过后端的非线性优化来更新滑窗内所有相机的位姿。紫线为闭环检测模块。当后端优化完成后，会将滑窗内的次新帧进行闭环检测，即首先提取新角点并进行描述，然后与数据库进行检索，寻找闭环帧，并将该帧添加到数据库中。红线为快照重定位模块，当检测到闭环帧后，会将闭环约束添加到后端的整体目标函数中进行非线性优化。得到第j帧（注意这里的帧为闭环帧中的老帧），经过滑窗优化后的位姿，从而计算出累积的偏移误差，进而对滑窗内的位姿进行修正。

这里，也可以在四自由度优化后PoseGraph::optimize4DoF()，将优化后的T_(w_1←w_2)，即对代码中的drift_correct_r, drift_correct_t, 被回传给后端优化线程，来更新滑窗内的相机位姿Estimator::update_loop_correction()。

8.其他

8.1 选KF策略

代码对应在addFeatureCheckParallax。

首先，迭代image即当前帧检测到的每个路标点id，看看图4中的feature队列中是否包含，若不含，则添加到feature队列中；若包含，则添加到对应id的FeaturePerFrame队列。

然后，compensatedParallax2计算每个路标点在两幅图中的视差量，若视差量大于某个阈值或者当前帧跟踪的路标点小于某个阈值，则边缘化滑窗内最老的帧；否则，边缘化掉新帧，即倒数第二帧。

8.2 后端优化后的变量更新

代码对应：Estimator::double2vector()，其中rot_diff是根据滑窗中第一帧在优化前后的yaw偏差计算得到的旋转矩阵，之后对滑窗内所有帧都进行rot_diff的校正。这是因为在后端滑动窗口的非线性优化时，我们并没有固定住第一帧的位姿不变，而是将其作为优化变量进行调整。但是，因为相机的偏航角yaw是不可观测的，也就是说对于任意的yaw都满足优化目标函数，因此优化之后我们将偏航角旋转至优化前的初始状态。

8.3 丢失后多地图融合

当丢失后，会从丢失位置重新初始化，并将相机位姿Pose修正为上次修正完drift后的Pose，并将posegraph中的drift清零，就修改R_(b_i)~w为R_(b_i,drift)~w，并在此基础上进行闭环优化。

同时，每次跟丢失后的地图视为新地图，并跟老地图一块放到database中进行闭环检测，只是sequence++，当闭环检测成功后，将新老地图进行对齐融合。

8.4 小滑窗PnP优化

为了控制后端滑窗优化的计算量，通常是每隔几帧（比如3帧）选一帧送到后端处理。为了计算被舍弃的帧的位姿，在VINS-Mobile版本中，加入了一种轻量级的基本小滑窗的PnP+IMU联合优化公式，对应在代码vins_pnp.cpp中，实现流程如下图所示：

1.当后端优化完成后，将滑窗内的最新帧（假设第i帧）的信息（时间戳、PVQ、bias）给到FeatureTracker的数据传输PnP，将滑窗中所有的路标点信息（id、P_w、bias）给到FeatureTracker的solved_features。另外，通过GetimuMeasurements()函数计算两帧之间的IMU数据，送给FeatureTracker的imu_msgs。注意这里的两帧是前端获得的新帧（假设第k帧，注意k>i）和上一个连续帧之间。如下图所示：

2.FeatureTracker::solveVinsPnP()中寻找第k帧中与滑窗中相同的路标点，计算该路标点在归一化相机系中的坐标，传给feature_msg；

3.vins_pnp::setInit()将PnP的小小滑窗（比如6个相邻帧）内的PVQ进行赋值，当滑窗内有第i帧时，则用从后端传过来的第i帧PVQ来更新；

4.processimu是进行第k-1帧和第k帧的预积分；

5.processImage中首先通过updateFeatures更新小小滑窗内的路标点位置P_w，最后调用solve_ceres来优化小小滑窗内的PVQ，不优化路标点，涉及的两个约束为：IMU的帧间约束，和每一帧的PnP（即每一帧的2D-3D观测量）的视觉重投影误差约束，因子图如下所示：

上图中，小方块为约束因子，圆圈为优化变量（这里路标点不是优化变量）：T=[v,b,a,w]，绿色小块为IMU约束，蓝色小块为PnP视觉约束。红色小块为先验约束，比如第k-4帧对应后端大滑窗的第i帧，因此信赖并固定住第k-4帧的T_(k-4)和M_(k-4)；另外，固定住所有帧的bias。

9.参考文献

[1] T. Qin. VINS-Mono: A robust and versatile monocular visual-inertial state estimator. arXiv preprint arXiv: 1708.03852, 2017.

[2] N. Tronvold. Indirect Kalman Filter for 3D Attitude Estimation. 2005.

[3] Sola. Quaternion kinematics for error-state kalman filter. 2017.

[4] K. Eckenhoff. Decoupled, Consistent Node Removal and Edge sparsification for graph-based SLAM. 2016.

[5] J. Engel. Direct Sparse Odometry. 2016.

[6] Sliding Window Filter with Application to Planetary Landing. 2010.

[7] S. Leutenegger. Keyframe-Based Visual-Inertial SLAM Using Nonlinear Optimization. 2015.

[8] VINS-Mono代码分析总结，https://www.yibaiduo.com/Xiaobuya/note/866099.

[9] 贺一一家，“SLAM中的marginalization和Schur complement”，https://blog.csdn.net/heyljia0327/article/details/52822104.

请点击阅读原文获取完整解读！

欢迎来到泡泡论坛，这里有大牛为你解答关于SLAM的任何疑惑。

有想问的问题，或者想刷帖回答问题，泡泡论坛欢迎你！

泡泡网站：www.paopaorobot.org

泡泡论坛：http://paopaorobot.org/bbs/

商业合作及转载请联系liufudiang_robot@hotmail.com

阅读原文

泡泡机器人SLAM

分享 • 深度 • 卓越 • 前沿

SLAM前沿技术领跑者，与你一同成长

Knowledge Worth Spreading

公开课 创闻 新闻 好书一起读 访谈 翻译

泡泡机器人SLAM的原创内容均由泡泡机器人的成员花费大量心血制作而成，希望大家珍惜我们的劳动成果。转载请注明出处「泡泡机器人SLAM」微信公众号，否则侵权必究！同时，我们也欢迎各位转载到自己的朋友圈，让更多的人进入到SLAM这个领域中，让我们共同为推进中国的SLAM事业而努力！

商业合作及转载请联系liufudiang_robot@hotmail.com

泡泡论坛：http://paopaorobot.org/bbs/

泡泡机器人SLAM的原创内容均由泡泡机器人的成员花费大量心血制作而成，希望大家珍惜我们的劳动成果。转载请注明出处「泡泡机器人SLAM」微信公众号，否则侵权必究！同时，我们也欢迎各位转载到自己的朋友圈，让更多的人进入到SLAM这个领域中，让我们共同为推进中国的SLAM事业而努力！